

# **Kom i gang med DAPLA**

Øyvind Bruer-Skarsbø

10/9/2022

# Innhold

|                               |           |
|-------------------------------|-----------|
| <b>Velkommen</b>              | <b>5</b>  |
| <b>Forord</b>                 | <b>6</b>  |
| <br>                          |           |
| <b>I Introduksjon</b>         | <b>7</b>  |
| 1 Hva er Dapla?               | 9         |
| 2 Hvorfor Dapla?              | 10        |
| 3 Arkitektur                  | 11        |
| 4 Innlogging                  | 12        |
| 5 Jupyterlab                  | 13        |
| 6 Bakke vs. sky               | 14        |
| <br>                          |           |
| <b>II Opprette Dapla-team</b> | <b>15</b> |
| 7 Hva er Dapla-team?          | 16        |
| 8 Opprette Dapla-team         | 17        |
| 9 Google Cloud Console        | 18        |
| 10 Lagre data                 | 19        |
| 11 Hente data                 | 20        |
| 12 Fra bakke til sky          | 21        |
| 13 Administrasjon av team     | 22        |

|                                      |           |
|--------------------------------------|-----------|
| <b>III Beste-praksis for koding</b>  | <b>23</b> |
| <b>14 SSB-project</b>                | <b>24</b> |
| 14.1 Opprett GitHub-bruker . . . . . | 25        |
| 14.2 Koble seg til SSB . . . . .     | 25        |
| 14.3 Autentifisering . . . . .       | 25        |
| 14.4 ssb-project-cli . . . . .       | 25        |
| <b>15 Git og Github</b>              | <b>26</b> |
| <b>16 Virtuelle miljøer</b>          | <b>27</b> |
| 16.1 Python . . . . .                | 27        |
| 16.2 R . . . . .                     | 27        |
| <b>17 Jupyter-kernels</b>            | <b>28</b> |
| <b>18 Installere pakker</b>          | <b>29</b> |
| 18.1 Python . . . . .                | 29        |
| 18.1.1 Installering . . . . .        | 29        |
| 18.1.2 Avinstallering . . . . .      | 29        |
| 18.1.3 Oppgradere pakker . . . . .   | 29        |
| 18.2 R . . . . .                     | 29        |
| 18.2.1 Installering . . . . .        | 29        |
| 18.2.2 Avinstallering . . . . .      | 29        |
| 18.2.3 Oppgradere pakker . . . . .   | 29        |
| <b>19 Samarbeid</b>                  | <b>30</b> |
| <b>20 Vedlikehold</b>                | <b>31</b> |
| <b>IV Jupyterlab på bakken</b>       | <b>32</b> |
| <b>21 Lese inn filer</b>             | <b>33</b> |
| 21.1 sas7bdat . . . . .              | 33        |
| 21.2 Oracle . . . . .                | 33        |
| 21.3 Fame . . . . .                  | 33        |
| 21.4 Tekstfiler . . . . .            | 33        |
| 21.5 Parquet . . . . .               | 33        |
| <b>V Avansert</b>                    | <b>34</b> |
| <b>22 IDE'er</b>                     | <b>35</b> |
| 22.1 RStudio . . . . .               | 35        |

|                         |           |
|-------------------------|-----------|
| 22.2 VSCode . . . . .   | 35        |
| 22.3 Pycharm . . . . .  | 35        |
| <b>23 Scheduling</b>    | <b>36</b> |
| <b>24 Databases</b>     | <b>37</b> |
| 24.1 BigQuery . . . . . | 37        |
| 24.2 CloudSQL . . . . . | 37        |
| <b>Referanser</b>       | <b>38</b> |

# Velkommen

DAPLA står for dataplattform og er SSBs nye plattform for statistikkproduksjon. Arbeidet startet som et utviklingsprosjekt i 2018 i sammenheng med Skatteetatens prosjekt *Sirius*. Idag er plattformen mer moden og klar for å ta imot flere statistikker. Denne boken er ment som

DAPLA står for dataplattform og er SSBs nye plattform for statistikkproduksjon. Arbeidet startet som et utviklingsprosjekt i 2018 i sammenheng med Skatteetatens prosjekt *Sirius*. Idag er plattformen mer moden og klar for å ta imot flere statistikker. Denne boken er ment som

**i** Denne boken er skrevet med [Quarto](#) og er publisert på <https://statisticsnorway.github.io/dapla-manual/>. Alle ansatte i SSB kan bidra til boken ved klone [dette repoet](#), gjøre endringer i en branch, og sende en pull request til administratorene av repoet (Team Statistiktjenester).

# Forord

Denne boken vil la SSB-ansatte ta i bruk grunnleggende funksjonalitet på DAPLA uten hjelp fra andre.

# **Part I**

## **Introduksjon**

Målet med dette kapitlet er å gi en grunnleggende innføring i hva som legges i ordet **Dapla**. I tillegg gis en forklaring på hvorfor disse valgene er tatt.



# **1 Hva er Dapla?**

## **2 Hvorfor Dapla?**

## 3 Arkitektur

Hvilke komponenter er plattformen bygd opp på? Forklart på lettest mulig måte.

## **4 Innlogging**

## 5 Jupyterlab

## 6 Bakke vs. sky

## **Part II**

# **Opprette Dapla-team**

## 7 Hva er Dapla-team?

Mer kommer



## **8 Opprette Dapla-team**

## **9 Google Cloud Console**

## 10 Lagre data

## 11 Hente data

## **12 Fra bakke til sky**

## **13 Administrasjon av team**

## **Part III**

# **Beste-praksis for koding**

## 14 SSB-project

Fremtidens produksjonsløp på **Dapla** bør følge noen helt klare retningslinjer for arbeidsprosesser og kode. Dette bør blant annet inkludere:

1. **Standard mappestruktur**

En standard mappestruktur gjør det lettere å dele og samarbeide om kode, som igjen reduserer sårbarheten knyttet til at få personer kjenner koden.

2. **Virtuelt miljø**

Virtuelle miljøer isolerer og lagrer informasjon knyttet til kode. For at publiserte tall skal være reproducerbare er SSB avhengig av at blant annet pakkeversjoner og versjon av Python/R lagres sammen med kode som er kjørt.

3. **Versjonshåndtering med Git**

Versjonshåndtering av kode er svært viktig for å kunne gjenskape og samarbeide om kode. [Git](#) er verdensstandarden for å gjøre dette, og derfor legges det opp til at all kode skal versjonshåndteres med Git i SSB.

4. **Lagre kode på Github**

På Dapla er det ingen fellesmappe som alle i SSB har tilgang til og hvor vi kan dele kode slik vi har gjort i bakkemiljøet tidligere. Kode som er versjonshåndtert med Git bruker som regel et remote repo<sup>1</sup> som er spesialsydd for Git og som skal deles med resten av verden hvis man ønsker. I SSB har vi valgt å bruke GitHub, der SSB har et eget område som heter [statisticsnorway](#).

[Team Statistikkjenester](#) har laget en CLI<sup>2</sup> som skal gjøre dette lett å implementere dette i kode. Den heter [ssb-project](#) og hjelper deg implementere det som til enhver tid er beste-praksis for koding.

Under vises det hvordan man bruker **ssb-project** til sette opp et prosjekt. Men programmet forutsetter at du har en GitHub-bruker som er knyttet opp mot [statisticsnorway](#). De første underkapitlene er derfor en beskrivelse av dette.

---

<sup>1</sup>Remote repo er en felle mappe som er lagret på en annen maskin. [Les mer her](#).

<sup>2</sup>CLI = Command-Line-Interface. Dvs. et program som er skrevet for å brukes terminalen ved hjelp av enkle kommandoer.



## 14.1 Opprett GitHub-bruker

Dette kapitlet er bare relevant hvis man ikke har en GitHub-brukerkonto fra før. For å bruke `ssb-project`-programmet til å generere et **remote repo** på GitHub må du ha en konto. Derfor starter vi med å gjøre dette. Det er en engangsjobb og du trenger aldri gjøre det igjen.

**i** SSB har valgt å ikke sette opp SSB-brukerne til de ansatte som GitHub-brukere. En viktig årsak er at en GitHub-konto ofte regnes som en del av den ansattes CV. For de som aldri har brukt GitHub før kan det virke fremmed, men det er nok en fordel på sikt når alle blir godt kjent med denne arbeidsformen.

Slik gjør du det:

1. Gå til <https://github.com/>
2. Trykk **Sign up** øverst i høyre hjørne
3. Svar på spørsmålene du blir stilt.

Husk at du lager en personlig konto uavhengig av SSB. Brukernavnet kan være noe annet enn brukernavnet ditt i SSB. I neste steg skal vi knytte denne kontoen til din SSB-bruker.

## 14.2 Koble seg til SSB

Hvis du har fullført forrige steg så har du nå en SSB-konto. Hvis du står på din profil-side så ser den slik ut:

## 14.3 Autentifisering

## 14.4 `ssb-project-cli`

## 15 Git og Github

# **16 Virtuelle miljøer**

## **16.1 Python**

Poetry bør benyttes for python. Mer kommer

## **16.2 R**

## 17 Jupyter-kernels

# **18 Installere pakker**

## **18.1 Python**

Mer kommer.

### **18.1.1 Installering**

### **18.1.2 Avinstallering**

### **18.1.3 Oppgradere pakker**

## **18.2 R**

### **18.2.1 Installering**

### **18.2.2 Avinstallering**

### **18.2.3 Oppgradere pakker**

## 19 Samarbeid

Noen har opprettet et ssb-project og pushet til Github. Hvordan skal kollegaer gå frem for å bidra inn i koden?

## 20 Vedlikehold

## **Part IV**

# **Jupyterlab på bakken**



## **21 Lese inn filer**

Mer kommer.

### **21.1 sas7bdat**

### **21.2 Oracle**

### **21.3 Fame**

### **21.4 Tekstfiler**

### **21.5 Parquet**

**Part V**

**Avansert**

## 22 IDE'er

Forklare situasjonen nå. Kun Jupyterlab. Kan kjøre remote session med Rstudio, Pycharm og VSCode.

### 22.1 RStudio

### 22.2 VSCode

### 22.3 Pycharm

## 23 Scheduling

## **24 Databaser**

### **24.1 BigQuery**

### **24.2 CloudSQL**

## Referanser