Kom i gang med DAPLA

Øyvind Bruer-Skarsbø

10/9/2022

Innhold

Ve	Velkommen Bidragsytere						
Forord							
I	Introduksjon	8					
1	Hva er Dapla?	10					
2	Hvorfor Dapla?	11					
3	Arkitektur	12					
4	Innlogging 4.1 Dapla <	13 14 18 18 18 18					
5	Jupyterlab 5.1 Hva er Jupyterlab? 5.2 Terminalen 5.3 Pakkeinstallasjoner 5.4 Extensions 5.5 Tips & triks	19 19 19 19 19					
6	Bakke vs. sky	20					
Ш	Opprette Dapla-team	21					
7	7 Hva er Dapla-team?						
R	Opprette Dapla-team	24					

9	Bøtter	25
	9.1 Bøttenavn i Produksjonsmiljøet	25
	9.2 Andre miljøer	
	9.3 Fellesbøtter	26
10	Google Cloud Console	27
11	Lagre data	28
12	Hente data	29
13	Fra bakke til sky	30
14	Administrasjon av team	31
Ш	Beste-praksis for koding	32
15	SSB-project	33
	15.1 Opprett ssb-project	34
	15.1.1 Opprett også på Github	35
	15.2 Bygg et eksisterende ssb-project	36
	15.3 Rydd opp etter deg	36
	15.4 Teknisk dokumentasjon	36
16	Git og Github	37
	16.1 Git	37
	16.1.1 Hva er Git?	37
	16.1.2 Oppsett av Git	38
	16.1.3 Git og Notebooks	38
	16.1.4 Vanlige Git-operasjoner	38
	16.2 GitHub	38
	16.2.1 Opprett GitHub-bruker	38
	16.2.2 To-faktor autentifisering	39
	16.2.3 Koble deg til SSB	43
	16.2.4 Personal Access Token (PAT)	43
17	Virtuelle miljøer	47
	17.1 Python	47
	17.1.1 Anbefalning	47
	17.2 R	47
18	Jupyter-kernels	48

19	Insta	illere pakker	49				
	19.1	Python	49				
		19.1.1 Poetry prosjekt eksempel	49				
		19.1.2 Installering	50				
		19.1.3 Avinstallering	50				
		19.1.4 Oppgradere pakker	50				
		19.1.5 Legge til kernel for poetry	50				
		20	51				
		19.1.6 Fjerne kernel	51				
	10.0	19.1.7 Sikkerhet					
	19.2	R	51				
		19.2.1 Installering	51				
		19.2.2 Avinstallering	53				
		19.2.3 Oppgradere pakker	53				
20	Sam	arbeid	54				
21	.,						
21	veai	ikehold	55				
IV	Jup	oyterlab på bakken	56				
22	Installere pakker						
		Python	57				
		22.1.1 Pip	57				
		22.1.2 Poetry	57				
	22.2	R	57				
	22.2	22.2.1 Installering	58				
		22.2.2 Avinstallering	58				
		22.2.3 Oppgradere pakker	58				
23		inn filer	59				
		sas7bdat	59				
	23.2	Oracle	59				
	23.3	Fame	59				
	23.4	Tekstfiler	59				
	23.5	Parquet	59				
V	Ava	ansert	60				
	_						
24		filer fra bøtte	61				
		Eksempler	61				
	24.2	Vanlige problemer	61				
		24.2.1 Feil miljø	61				

Re	eferanser	66
	27.2 CloudSQL	65
	27.1 BigQuery	
27	7 Databaser	65
26	Schedulering Schedulering	64
	25.3 Pycharm	63
	25.2 VSCode	
	25.1 RStudio	
25	5 IDE'er	63
	24.2.3 Opprett TMS sak	62
	24.2.2 Omstart av Jupyter	

Velkommen

Denne boken er ment som enkel-å-bruke manual for å ta i bruk SSBs nye dataplattform Dapla. Plattformen forsøker å gjøre statistikkprodusenter og forskere så selvhjulpne som mulig. Målsetningen er at tjenestene som tilbys skal kunne tas i bruk på en enkel og intuitiv måte. Men uansett hvor lett tilgjengelig tjenester er, og hvor mye arbeid som er lagt å gjøre løsninger brukervennlige, så trenger de fleste i SSB en klar og tydelig veiledning for hvordan de skal brukes og i hvilken større sammenheng tjenestene inngår. Dapla-manualen er ment å være en sånn støtte i statistikkernes hverdag. Uansett om man lurer på hvordan man logger seg inn på plattformen, eller om man ønsker informasjon om kjøremiljøet for mer kompliserte maskinlæringsmodeller, så skal man finne veiledning i denne manualen. Målgruppen er både nybegynneren og den mer erfarne.

Denne boken er skrevet med Quarto og er publisert på https://statisticsnorway.github. io/dapla-manual/. Alle ansatte i SSB kan bidra til boken ved klone dette repoet, gjøre endringer i en branch, og sende en pull request til administratorene av repoet (Team Statistikktjenester).

Bidragsytere

Dapla-manualen er initiert og skrevet av **Team Statistikktjenester** i SSB. Bidragsytere er Øyvind Bruer-Skarsbø, Miles Winther, Bjørn Andre Skaar og Anders Lunde. Ved behov for oppdateringer og nytt innhold håper vi at alle i SSB kan bidra.

Forord

Denne boken tar sikte på å gi SSB-ansatte mulighet til å ta i bruk grunnleggende funksjonalitet på DAPLA uten hjelp fra eksperter. Boken er bygget opp som den reisen vi mener en statistikker skal gjennom når de flytter sin produksjon fra bakke til sky¹. Første del inneholder en del grunnleggende kunnskap som vi mener er viktig å ha før man skal starte å jobbe i skyen. Andre del forklarer hvordan man søker om å opprette et Dapla-team, en forutsetning for å drive databehandling på plattformen. Det vil ofte være første steget i ta i bruk plattformen, siden det er slik man får et sted å lagre data. Her forklarer vi hvilke tjenester som inkluderes i et statistikkteam og hvordan man bruker og administerer dem. Den tredje delen tar utgangspunkt i at man skal starte å kode opp sin statistikkproduksjon eller kjøre eksisterende kode. ssb-project er et verktøy som er utviklet i SSB for å gjøre denne prosessen så enkel som mulig. Da kan brukerne implementere det som anses som god praksis i SSB med noen få tastetrykk, samtidig som vi også forklarer mer detaljert hva som skjer under panseret.

Det er tilrettelagt for en treningsarena i bakkemiljøet. Dette miljøet er nesten identisk med det som møter deg på Dapla, med unntak av at du her har tilgang til mange av de gamle systemene og mye mindre hestekrefter i maskinene. Ideen er at SSB-ere ofte vil ønske å lære seg de nye verktøyene² i kjente og kjære omgivelser først, og deretter flytte et ferdig skrevet produksjonsløp til Dapla. Del 4 av denne boken beskriver mer utfyllende hvordan dette miljøet skiller seg fra Dapla, og hvordan man gjør en del vanlige operasjoner mot de gamle bakkesystemene.

Siste delen av boken kaller vi **Avansert** og tar for seg ulike emner som mer avanserte brukere typisk trenger informasjon om. Her finner man blant annet informasjon om hvilke databaser man kan bruke og hvilke formål de er egnet for. Her beskrives også hvordan man kan bruke andre IDE-er enn Jupyterlab hvis man ønsker det. Tjenester for schedulerte kjøringer av Notebooks blir også diskutert.

Forhåpentligvis senker denne boken terskelen for å ta i bruk Dapla. Kommentarer og ønsker vedrørende boken tas imot med åpne armer.

God fornøyelse

¹I denne boken omtaler vi den gamle produksjonssonen, ofte kalt prodsonen, som **bakke**, og det nye skymiljøet Google Cloud som **sky**. Det er ikke helt presist men duger for formålene i denne boken.

²Det som omtales som nye verktøy er vil som regel bety R, Python, Git, GitHub og Jupyterlab.

Part I Introduksjon

Målet med dette kapitlet er å gi en grunnleggende innføring i hva som legges i ordet **Dapla**. I tillegg gis en forklaring på hvorfor disse valgene er tatt.

1 Hva er Dapla?

Dapla står for **dataplattform**, og er en skybasert løsning for statistikkproduksjon og forskning.

2 Hvorfor Dapla?

Som dataplattform skal Dapla stimulerere til økt kvalitet på statistikk og forskning, samtidig som den gjør organisasjonen mer tilpasningsdyktig i møte med fremtiden.

Den nye skybaserte dataplattformen (Dapla) skal bli viktig for å effektivisere arbeids-og produksjons Kilde: Langtidsplan for SSB (2022-2024)

Målet med Dapla er å tilby tjenester og verktøy som lar statistikkprodusenter og forskere produsere resultater på en sikker og effektiv måte.

3 Arkitektur

Hvilke komponenter er plattformen bygd opp på? Forklart på lettest mulig måte.

4 Innlogging

Innlogging på Dapla er veldig enkelt. Dapla er en nettadresse som alle SSB-ere kan gå inn på hvis de er logget på SSB sitt nettverk. Å være logget på SSB sitt nettverk betyr i denne sammenhengen at man er logget på med **VPN**, enten man er på kontoret eller på hjemmekontor. For å gjøre det enda enklere har vi laget en fast snarvei til denne nettadressen på vårt intranett/Byrånettet(se Figure 4.1).




Figure 4.1: Snarvei til Dapla fra intranett

Men samtidig som det er lett å logge seg på, så er det noen kompliserende ting som fortjener en forklaring. Noe skyldes at vi mangler et klart språk for å definere bakkemiljøet og skymiljøet slik at alle skjønner hva man snakker om. I denne boken definerer bakkemiljøet som stedet der man har drevet med statistikkproduksjon de siste tiårene. Skymiljøet er den nye dataplattformen **Dapla** på Google Cloud.

Det som gjør ting litt komplisert er at vi har 2 Jupyter-miljøer på både bakke og sky. Årsaken er at vi har ett test- og ett prod-område for hver, og det blir i alt 4 Jupyter-miljøer. Figure 4.2 viser dette.

Hver av disse miljøene har sin egen nettadresse og sitt eget bruksområde.

4.1 Dapla

I de fleste tilfeller vil en statistikker eller forsker ønske å logge seg inn i prod-miljøet. Det er her man skal kjøre koden sin i et produksjonsløp som skal publiseres eller utvikles. I noen tilfeller hvor man ber om å få tilgjengliggjort en ny tjeneste så vil denne først rulles ut i testområdet som vi kaller **staging-området**. Årsaken er at vi ønsker å beskytte prod-miljøet fra software

Bakkemiljø	Skymiljø/Dapla
PROD	PROD
STAGING	STAGING

Figure 4.2: De 4 Jupyter-miljøene i SSB. Et test-miljø og et prod-miljø på bakke og sky/Dapla

som potensielt ødelegger for eksisterende funksjonalitet. Derfor ruller vi ut nye ting i staging først. Av den grunn vil de fleste oppleve å bli bedt om å logge seg inn der for testing en eller annen gang. Under forklarer vi hvordan man går frem for å logge seg på de to ulike miljøene på Dapla.

4.1.1 Prod

For å logge seg inn inn i prod-miljøet på Dapla kan man gjøre følgende:

- 1. Gå inn på lenken https://jupyter.dapla.ssb.no/ i en Chrome-nettleser eller klikk på lenken på Byrånettet som vist i Figure 4.1.
- 2. Alle i SSB har en Google Cloud-konto som må brukes når man logger seg på Dapla. Brukernavnet i Google er det samme som din *korte* epost-adresse (f.eks. cth@ssb.no). Hvis du ikke allerede er logget inn i Google vil du få spørsmål om å velge hvilken Google-konto som skal brukes (Figure 4.3). Logg inn med din Google-konto (ssb.no) og ditt AD-passord.
- 3. Deretter blir man spurt om man godtar at ssb.no (altså Dapla) kan bruke din Google Cloud-konto (Figure 4.4). Trykk **Allow**.
- 4. Deretter lander man på en side som lar deg avgjøre hvor mye maskinkraft som skal holdes av til deg (Figure 4.5). Det øverste alternativet er valgt som standard, og er tilstrekkelig for de fleste.
- 5. Vent til maskinen din starter opp (Figure 4.6). Oppstartstiden kan variere.




Figure 4.3: Velg en Google-konto




Figure 4.4: Tillat at ssb.no får bruke din Google Cloud-konto

Server Options

Jupyter arbeidsmiljø

Standard arbeidsmiljø for Notebooks med Python og R på Dapla

Jupyter for kjøring av produksjonsløp

Serveren kan trenge ekstra oppstartstid.

Denne jupyterinstansen gir garantier for mengde maskinkraft du får tildelt, noe som gir stabilitet og fart når du kjører et produksjonsløp.

Jupyter stor maskin

NB! Denne er dyr å bruke, og skal KUN brukes for tunge beregninger. Serveren kan trenge ekstra oppstartstid.

Denne jupyterinstansen gir ekstra mye minne og prosessorkraft, for spesielle arbeidsoppgaver hvor det kreves.

Star

Figure 4.5: Velg hvor mye maskinkraft du trenger




Figure 4.6: Starter opp Jupyter

Etter dette er man logget inn i et Jupyter-miljø som kjører på en minimal Ubuntu-maskin. Hvis man er del av et Dapla-team får man også tilgang til alt teamet har tilgang til.

4.1.2 Staging

Innlogging til staging-miljøet er identisk med innloggingen til prod-miljøet, med ett viktig unntak: nettadressen er nå https://jupyter.dapla-staging.ssb.no/.

Litt mer om hva som er tilgjenglig her kommer.

4.2 Bakkemiljøet

Jupyter-miljøet på bakken bruker samme base-image¹ for å installere Jupyterlab, og er derfor identisk på mange måter. Men innloggingen er ganske forskjellig.

4.2.1 Prod

Du logger deg inn på prod i bakkemiljøet på følgende måte:

- 1. Logg deg inn på Citrix-Windows i bakkemiljøet. Det kan gjøres ved å bruke lenken Citrix på Byrånettet, som også vises i Figure 4.1.
- 2. Åpne Chrome-nettleseren
- 3. Gå inn på denne nettadressen: https://sl-jupyter-p.ssb.no/
- 4. Skriv inn ditt brukernavn og passord som du bruker når du logger deg på maskinen din hver morgen.

4.2.2 Staging

Innlogging til staging-miljøet er identisk med innloggingen til prod-miljøet, med ett viktig unntak: nettadressen er nå https://sl-jupyter-t.ssb.no/.

¹ Hv2 or	base-image?	
¹Hva er	base-image?	

5 Jupyterlab

5.1 Hva er Jupyterlab?

Mer kommer.

5.2 Terminalen

Må nevne operativsystemet og at noe programvare ligger installert her (git, jwsacruncher, quarto, ++)

5.3 Pakkeinstallasjoner

Noe er i base-image, noe bør gjøres i virtuelle miløer. Hvordan liste ut pakker som er pre-installert?

5.4 Extensions

Jupyterlab er en samling extension. Kan bare installeres av admin. Sikkerhet. Hvilke extension har vi tilgjengeliggjort?

5.5 Tips & triks

Sane defaults for Jupyterlab.

6 Bakke vs. sky

Part II Opprette Dapla-team

Dette kapitlet beskriver hva et Dapla-team er og hvordan man går frem for å opprette et nytt team på Dapla.

7 Hva er Dapla-team?

Et Dapla-team fokuserer på statistikkproduksjon innen et eller flere emneområder på Dapla. Teamet er egentlig et arbeidsområde på Dapla, som gir medlemmene av teamet tilgang på teamet sine felles datalagre, roller og bakke-sky synkroniseringsområder.

Hvert Dapla-team får opprettet et prosjektområde i Google Cloud Platform (GCP), som er SSBs leverandør av skytjenester.

8 Opprette Dapla-team

For å komme i gang med å opprette et Dapla-team trengs det en oversikt over teamets medlemmer og hvilke tilgangsgrupper medlemmene skal være med i. Det trengs også informasjon om hvilke Dapla-tjenester som er aktuelle for teamet å ta i bruk. Derfor har det blitt opprettet en egen veileder for dette kalt *Dapla Start*.

Gå til Dapla Start for starte bestilling av et nytt Dapla-team.

Når teamet er opprettet får alle medlemmene tilgang til sitt eget prosjekt i Google Cloud Platform (GCP), som er SSBs leverandør av skytjenester. Videre får hvert prosjekt et sett med tjenester og tilganger som knyttes til teamet. Det opprettes også datalagringsområder (kalt "bøtter") som bare kan aksesseres av brukere som er med i teamets tilgangsgrupper.

9 Bøtter

Hvert statistikkteam har sitt eget datalager som heter Google Cloud Storage (GCS). Disse er delt inn i flere datalagringsområder som kalles $b \emptyset t t e r$. Dette kan sees på som et filsystem som kan organiseres med flere undermapper og filer. Navnet på b $\emptyset t t e r$ må være unikt på tvers av alle Dapla-team. Derfor blir disse opprettet etter en navnekonvensjon basert på kj $\emptyset r e r$ teamnavn og hvilke data b $\emptyset t t a$ skal inneholde.

9.1 Bøttenavn i Produksjonsmiljøet

- ssb-prod-teamnavn-data-kilde: Inneholder pseudonymiserte rådata fra datakildene
- ssb-prod-teamnavn-data-produkt: Inneholder data knyttet til statistikkproduktet, med følgende underkataloger:
 - inndata
 - klargjorte-data
 - statistikk
 - utdata
- ssb-prod-teamnavn-data-delt: Inneholder data knyttet til statistikkproduktet som kan deles med andre statistikkteam. Disse vil ha følgende underkataloger:
 - inndata
 - klargjorte-data
 - statistikk
 - utdata
- Underkatalogene inndata, klargjorte-data, statistikk og utdata gjenspeiler SSBs datatil-stander. Se Datatilstander i SSB for mer informasjon.

9.2 Andre miljøer

På samme måte som i produksjonsmiljøet finnes det bøtter for utviklings- og testformål:

- \bullet ssb-staging-teamnavn-data-kilde
- \bullet ssb-staging-teamnavn-data-produkt
- $\bullet \ \, {
 m ssb\text{-}staging-} teamnavn\text{-} {
 m data-} {
 m delt}$

9.3 Fellesbøtter

I tillegg til disse finnes det noen bøtter med data som kan deles med alle i SSB og og som kan brukes til kurs og opplæring (bl.a. denne manualen). Disse bøttene er:

- $\bullet \ \, ssb ext{-prod-dapla-data-delt}$
- $\bullet \ \ ssb\text{-staging-dapla-data-delt}$

10 Google Cloud Console

Google Cloud er SSBs leverandør av skytjenester som Dapla er bygget på.

Google Cloud Console er et web-basert grensesnitt for å administrere ressurser og tjenester på Google Cloud. For å bruke denne må man ha en Google-konto. Alle i SSB har en konto knyttet opp mot Google.

Gå til Google Cloud Console og logg på med din SSB-bruker.

11 Lagre data

12 Hente data

13 Fra bakke til sky

14 Administrasjon av team

Part III Beste-praksis for koding

15 SSB-project

Produksjonsløp på **Dapla** kan med fordel følge noen helt klare retningslinjer for arbeidsprosesser og kode. Dette bør blant annet inkludere:

- 1. **Standard mappestruktur** En standard mappestruktur gjør det lettere å dele og samarbeide om kode, som igjen reduserer sårbarheten knyttet til at få personer kjenner koden.
- 2. **Virtuelt miljø** Virtuelle miljøer isoloerer og lagrer informasjon knyttet til kode. For at publiserte tall skal være reproduserbare er SSB avhengig av at blant annet pakkeversjoner og versjon av Python/R lagres sammen med kode som er kjørt.
- 3. **Versjonshåndtering med Git** Versjonshåndtering av kode er svært viktig for å kunne gjenskape og samarbeide om kode. Git er verdensstandarden for å gjøre dette, og derfor legges det opp til at all kode skal versjonshåndteres med Git i SSB.
- 4. Lagre kode på Github På Dapla er det ingen fellesmappe som alle i SSB har tilgang til og hvor vi kan dele kode slik vi har gjort i bakkemiljøet tidligere. Kode som er versjonshåndtert med Git bruker som regel et remote repo¹ som er spesialsydd for Git og som skal deles med resten av verden hvis man ønsker. I SSB har vi valgt å bruke GitHub, der SSB har et eget område som heter statisticsnorway.

Team Statistikktjenester har laget en CLI² som skal gjøre dette lett å implemententere dette i kode. Den heter ssb-project og hjelper deg implementere det som til enhver tid er beste-praksis for koding.

Under vises det hvordan man bruker ssb-project til sette opp et prosjekt. Men programmet forutsettet at du har en GitHub-bruker som er knyttet opp mot statisticsnorway. Dette beskrives på Git og Github siden.

 $^{^1}Remote\ repo$ kan anses som en felles mappe som er lagret på en annen maskin. Les mer her.

²CLI = Command-Line-Interface. Dvs. et program som er skrevet for å brukes terminalen ved hjelp av enkle kommandoer.

15.1 Opprett ssb-project

🛕 Har du Github bruker? Noe funksjonalitet i ssb-project krever det. Finne ut hvordan å opprette en på Git og Github siden.

Programmet ssb-project skal gjøre det enklere å organiserer kode etter god praksis i en statistikkproduksjoner. Som nevnt i innledningen vil progammet gi deg en mappestruktur, virtuelt miljø og en jupyter-kernel. Hvis du ønsker kan det også opprette et GitHub-repo. Ønsker du alt gjør du følgende:


- 1. Åpne en terminal. De fleste vil gjøre dette i Jupyterlab på bakke eller sky og da kan de bare trykke på det blå +-tegnet i Jupyterlab og velge **Terminal**.
- 2. Før vi kjører programmet må vi være obs på at ssb-project vil opprette en ny mappe der vi står. Gå derfor til den mappen du ønsker å ha den nye prosjektmappen. For å opprette et prosjekt som heter **stat-testprod** så skriver du følgende i terminalen:

ssb-project create stat-testprod

Hvis du stod i hjemmemappen din på når du skrev inn kommandoen over i terminalen, så har du fått mappestrukturen som vises i bildet til høyre. ³. Den inneholder følgende:

- .git-mappe som blir opprettet for å versjonshåndtere med Git.
- src-mappe som skal inneholde all koden som utgjør produksjonsløpet.
- tests-mappe som inneholder tester du skriver for koden din.
- LICENCE-fil som skal benyttes for public-repos i SSB.
- poetry.lock-fil som inneholder alle versjoner av Python-pakker som blir brukt.
- README.md-fil som brukes for tekstlig innhold på GitHub-siden for prosjektet.

³Filer og mapper som starter med punktum er skjulte med mindre man ber om å se dem. I Jupyterlab kan disse vises i filutforskeren ved å velge View fra menylinjen, og deretter velge Show hidden files. I en terminal skriver man 1s -a for å se de.




15.1.1 Opprett også på Github

Over så opprettet vi et ssb-project uten å opprette et GitHub-repo med samme navn. Hvis du ønsker å opprette et GitHub-repo også må du endre kommandoen over til:

```
ssb-project create stat-testprod --github --github-token='blablabla'
```

Kommandoen over oppretter en mappestruktur slik vi så tidligere, men også et ssb-project som heter **stat-testprod** med et GitHub-repo med samme navn. Repoet i GitHub ser da slik ut:



15.2 Bygg et eksisterende ssb-project

Hvis kollegaen din har opprettet et prosjekt vha. ssb-project, så kan du enkelt ta det i bruk på din Jupyter server:

- 1. Klone report med git clone https://github.com/statisticsnorway/opiektnavn>
- 2. Gå til mappen med cd prosjektnavn>
- 3. Skape et virtuelt miljø og installere en tilsvarende Jupyter kernel med ssb-project build

15.3 Rydd opp etter deg

Hvis man jobber med flere prosjekter så kan det fort bli mange Jupyter kerneler hengende igjen. Derfor er det også mulighet å kjøre ssb-project clean stat-testprod som sletter Jupyter kernelen for prosjektet.

15.4 Teknisk dokumentasjon

Dokumentasjonen for ssb-project finnes her: https://statisticsnorway.github.io/ssb-project-cli/

Det oppdateres hver gang en ny versjon av ssb-project er slippet ut.

16 Git og Github

I SSB anbefales det man versjonhåndterer koden sin med Git og deler koden via GitHub. For å lære seg å bruke disse verktøyene på en god måte er det derfor viktig å forstå forskjellen mellom Git og Github. Helt overordnet er forskjellen følgende:

- Git er programvare som er installert på maskinen du jobber på og som sporer endringer i koden din.
- GitHub er et slags felles mappesystem på internett som lar deg dele og samarbeide med andre om kode.

Av definisjonene over så skjønner vi at det er **Git** som gir oss all funksjonalitet for å lagre versjoner av koden vår. GitHub er mer som et valg av mappesystem. Men måten kodemiljøene våre er satt opp på **Dapla** så har vi ingen fellesmappe som alle kan kjøre koden fra. Man utvikler kode i sin egen hjemmemappe, som bare du har tilgang til, og når du skal samarbeide med andre, så må du sende koden til GitHub. De du samarbeider med må deretter hente ned denne koden før de kan kjøre den.

I dette kapitlet ser vi nærmere på Git og Github og hvordan de er implementert i SSB. Selv om SSB har laget programmet **ssb-project** for å gjøre det lettere å bl.a. forholde seg til Git og GitHub, så vil vi dette kapitlet forklare nærmere hvordan det funker uten dette hjelpemiddelet. Forhåpentligvis vil det gjøre det lettere å håndtere mer kompliserte situasjoner som oppstår i arbeidshverdagen som statistikker.

16.1 Git

Git er terminalprogram som installert på maskinen du jobber. Hvis man ikke liker å bruke terminalen finnes det mange pek-og-klikk versjoner av Git, blant annet i Jupyterlab, SAS EG og RStudio. Men typisk vil det en eller annen gang oppstå situasjoner der det ikke finnes løsninger i pek-og-klikk versjonen, og man må ordne opp i terminalen. Av den grunn velger vi her å fokusere på hvordan Git fungerer fra terminalen. Vi vil også fokusere på hvordan Git fungerer fra terminalen i Jupyterlab på Dapla.

16.1.1 Hva er Git?

Kommer snart. Kort forklaring med lenke til mer utfyllende svar.

16.1.2 Oppsett av Git

Kommer snart. Scriptet til Kvakk.

16.1.3 Git og Notebooks

Kommer snart. Jupytext og nbsripout. json.

16.1.4 Vanlige Git-operasjoner

Kommer snart. clone, add, commit, push, pull, merge, revert, etc.

16.2 GitHub

16.2.1 Opprett GitHub-bruker

Dette kapitlet er bare relevant hvis man ikke har en GitHub-brukerkonto fra før. For å bruke ssb-project-programmet til å generere et **remote repo** på GitHub må du ha en konto. Derfor starter vi med å gjøre dette. Det er en engangsjobb og du trenger aldri gjøre det igjen.

SSB har valgt å ikke sette opp SSB-brukerne til de ansatte som GitHub-brukere. En viktig årsak er at er en GitHub-konto ofte regnes som en del av den ansattes CV. For de som aldri har brukt GitHub før kan det virke fremmed, men det er nok en fordel på sikt når alle blir godt kjent med denne arbeidsformen.


Slik gjør du det:

- 1. Gå til https://github.com/
- 2. Trykk **Sign up** øverst i høyre hjørne
- 3. Svar på spørsmålene du blir stilt.

Husk at du lager en personlig konto uavhengig av SSB. Brukernavnet kan være noe annet enn brukernavnet ditt i SSB. I neste steg skal vi knytte denne kontoen til din SSB-bruker.


16.2.2 To-faktor autentifisering

Hvis du har fullført forrige steg så har du nå en GitHub-konto. Hvis du står på din profil-side så ser den slik ut:



Det neste vi må gjøre er å aktivere 2-faktor autentifisering, siden det er dette som benyttes i SSB. Hvis du står på siden i bildet over, så gjør du følgende for å aktivere 2-faktor autentifisering mot GitHub:


- 1. Trykk på den lille pilen øverst til høyre og velg **Settings**(se bilde til høyre).
- 2. Deretter velger du Password and authentification i menyen til venstre.



3. Under Two-factor authentication trykker du på Add. Da får du opp følgende bilde:



- 4. Strekkoden over skal skannes i din **Microsoft Authenticator**-app på mobilen. Åpne appen, trykk på **Bekreftede ID-er**, og til slutt trykk på **Skann QR-kode**. Deretter skanner du QR-koden fra punkt 3.
- 5. Når koden er skannet har du fått opp følgende bilde på appens hovedside (se bilde til høyre). Skriv inn den 6-siffer koden på GitHub-siden med QR-koden.
- 6. Til slutt lagrer du **Recovery-codes** et trygt sted.



Nå har vi aktivert 2-faktor autentifisering for GitHub og er klare til å knytte vår personlige konto til vår SSB-bruker på SSBs "Github organisation" **statisticsnorway**.

16.2.3 Koble deg til SSB

I forrige steg aktiverte vi 2-faktor autentifisering for GitHub. Det neste vi må gjøre er å bruke denne autentiseringen til å koble oss til SSB sin organisasjon **statisticsnorway**. Det er dette som gjør at vi kan jobbe med SSB-kode som ligger lagret på GitHub.

- 1. Gå til profilsiden din og velg **Settings** slik du gjorde i punkt 1 i forrige delkapitel.
- 2. Trykk deretter på **Organizations** i menyen til venstre.
- 3. Trykk deretter på New organization.
- 4. Søk etter **statisticsnorway**.


16.2.4 Personal Access Token (PAT)

Når vi skal jobbe med SSB-kode som ligger lagret hos **statistcsnorway** på GitHub, så må vi autentisere oss. Måten vi gjøre det på er ved å generere et **Personal Access Token** (ofte forkortet PAT) som vi oppgir når vi vil hente eller oppdatere kode på GitHub. Da sender vi med PAT for å autentisere oss for GitHub.

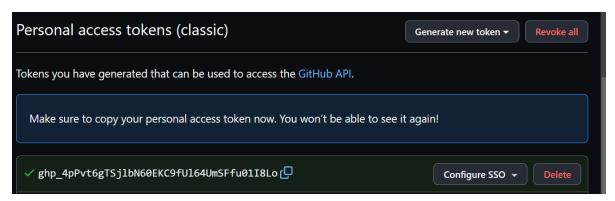
16.2.4.1 Opprette PAT

For å lage en PAT som er godkjent mot statisticsnorway så gjør man følgende:


- 1. Gå til din profilside på GitHub og åpne **Settings** slik som ble vist Section 16.2.2.
- 2. Velg **Developer Settings** i menyen til venstre.
- 3. I menyen til venstre velger du **Personal Access Token**, og deretter **Tokens (classic)**.
- 4. Under **Note** kan du gi PAT'en et navn. Velg et navn som er intuitivt for deg. Hvis du skal bruke PAT til å jobbe mot Dapla, så ville jeg ganske enkelt kalt den *dapla*. Hvis du skal bruke den mot bakkemiljøet ville jeg kalt den *prodsone* eller noe annet som gjør det lett for det skjønne innholdet i ettertid.
- 5. Under **Expiration** velger du hvor lang tid som skal gå før PAT blir ugyldig. Dette er en avvening mellom sikkerhet og hva som er praktisk. En grei mellomløsning kan være å velge 3 måneder. Når PAT utløper må du gjenta stegene i dette kapitlet.
- 6. Under **Select scopes** velger du **Repo** (se bilde under).



8. Trykk på Generate token nederst på siden og du får opp noe som ser ut som dette:



- 9. Kopier deretter PAT til en midlertidig fil. Grunnen er at du aldri vil se det igjen her etter at vi har gjennomført neste steg.
- 10. Deretter trykker du på **Configure SSO** og velger **Authorize** ved siden statisticsnorway. Svar deretter på spørsmålene som dukker opp.



Vi har nå opprettet en PAT som er godkjent for bruk mot SSB sin kode på GitHub. Det betyr at hvis vi vil jobbe med **Git** på SSB sine maskiner i sky eller på bakken, så må vi sendte med dette tokenet for å få lov til å jobbe med koden som ligger på **statisticsnorway** på GitHub.

16.2.4.2 Lagre PAT

Det er ganske upraktisk å måtte sende med tokenet hver gang vi skal jobbe med GitHub. Vi bør derfor lagre det lokalt der vi jobber, slik at Git automatisk finner det. Det finnes mange måter å gjøre dette på og det er ikke bestemt hva som skal være beste-praksis i SSB. Men en måte å gjøre det er via en .netrc-fil. Vi oppretter da en fil som heter .netrc på vårt hjemmeområde, og legger følgende informasjon på en (hvilken som helst) linje i filen:

machine github.com login <github-bruker> password <Personal Access Token>

GitHub-bruker er da din personlige bruker og IKKE brukernavnet ditt i SSB. Personal Access Token er det vi lagde

En veldig enkel måte å lagre dette er som følger. Anta at min personlige GitHub-bruker er **SSB-Chad** og at min Personal Access Token er **blablabla**. Da kan jeg gjøre følgende for å lagre det i .netrc:

- 1. Gå inn i Jupyterlab og åpne en Python-notebook.
- 2. I den første kodecellen skriver du: !echo "machine github.com login SSB-Chad password blablabla" >> ~/.netrc

Alternativt kan du droppe det utropstegnet og kjøre det direkte i en terminal. Det vil gi samme resultat. Koden over legger til en linje med teksten **machine github.com login SSB-Chad password blablabla** i en .netrc-fil på din hjemmeområdet, uanvhengig av om du har en fra før eller ikke. Hvis du har en fil fra før som allerede har et token fra GitHub, ville jeg nok slettet det før jeg legger en et nytt token.

Hver gang du jobber mot GitHub vil Git sjekke om informasjon om autentifisering ligger i denne filen, og bruke den hvis den ligger der.

16.2.4.3 Oppdater PAT

I eksempelet over lagde vi en PAT som var gyldig i 90 dager. Dermed vil du ikke kunne jobbe mot GitHub med dette tokenet etter 90 dager. For å oppdatere tokenet gjør du følgende:

- 1. Lag et nytt PAT ved å repetere Section 16.2.4.1.
- 2. I miljøet der du skal jobbe med Git og GitHub går du inn i din .netrc og bytter ut token med det nye.

Og med det er du klar til å jobbe mot statisticsnorway på GitHub.

17 Virtuelle miljøer

17.1 Python

Et python viretuelt miljø inneholder en spesifikk versjon av python og et sett med pakker. Pakkene er kun tilgjengelige når det viretuelt miljøet er aktivert. Dette gjør at man ungår avhengighetskonflikter på tvers av prosjekter.

Se her for mer informasjon om viretuelle miljøer.

17.1.1 Anbefalning

Det er anbefalt å benytte verktøyet poetry for å administrere prosjekter og deres viretuelle miljø.

Poetry setter opp virtuelt miljø, gjør det enkelt å oppdatere avhengigheter, sette versjons begrensninger og reprodusere prosjektet.

Poetry gjør dette ved å lagre avhengigheters eksakte versjon i prosjektets "poetry.lock". Og eventuelle begrensninger i "pyproject.toml". Dette gjør det enkelt for andre å bygge prosjektet med akkurat de samme pakkene og begrensningene.

17.2 R

18 Jupyter-kernels

19 Installere pakker

19.1 Python

Installering av pakker er kun er mulig I et virtuelt miljø. Det er anbefalt å benytte poetry til dette. Eksemplene videre tar derfor utgangspunkt i et poetry prosjekt.

Det er mulig å installere pakker med pip. Pakker kan installeres som normalt, hvis man har satt opp og aktivert et virtuelt miljø.

19.1.1 Poetry prosjekt eksempel

Dette eksemplet viser hvordan man setter oppe et enkelt poetry prosjekt kalt test, hvis man ønsker å benytte et annet prosjektnavn må man endre dette i hver av kommandoene.

Sett opp prosjektet:

```
poetry new test
```

Naviger inn i prosjektmappen:

```
cd test
```

Bruk poetry install for å bygge prosjektet:

```
poetry install
```

Hvis man får en tilbakemelding som denne er prosjektet satt opp korrekt:

```
Creating virtualenv test-EojoH6Zm-py3.10 in /home/jovyan/.cache/pypoetry/virtualenvs Updating dependencies Resolving dependencies... (0.1s)

Writing lock file
```

19.1.2 Installering

For å legge til pakker i et prosjekt benyttes kommandoen poetry add.

Skal man legge til pakken "pendulum" vil det se slik ut:

```
poetry add pendulum
```

Poetry tilbyr måter å sette versjonsbegrensninger for pakker som legges til i et prosjekt, dette kan man lese mer om her.

19.1.3 Avinstallering

For å fjerne pakker fra et prosjekt benytter man poetry remove.

Hvis man ønsker å fjerne "pendulum" fra et prosjekt vil kommandoen se slik ut:

```
poetry remove pendulum
```

19.1.4 Oppgradere pakker

For å oppdatere pakker i et prosjekt benytter man kommandoen poetry update.

Skal man oppdatere pakken "pendulum" bruker man:

```
poetry update pendulum
```

Skal man oppdatre alle pakken i et prosjekt benytter man:

```
poetry update
```

19.1.5 Legge til kernel for poetry

For å kunne benytte det virtuelle miljøet i en notebook må man sette opp en kernel. Kernel burde gis samme navn som prosjektet.

Først legger man til ipykernel:

```
poetry add ipykernel
```

Så opprettes kernel med:

```
poetry run python -m ipykernel install --user --name test
```

Etter dette er kernelen test opprettet og kan velges for å benytte miljøet i en notebook.

19.1.6 Fjerne kernel

For å fjerne en kernel med navn test bruker man:

```
jupyter kernelspec remove test
```

Du vil bli spurt om å bekrefte, trykk y hvis man ønsker å slette:

Etter dette er kernelen fjernet.

19.1.7 Sikkerhet

Hvem som helst kan legge til pakker på PyPi, det betyr at de i verstefall, kan inneholde skadelig kode. Her er en list med viktige tiltak som minimere risikoen:

- a) Før man installerer pakker bør man alltid søke de opp på https://pypi.org. Det er anbefalt å klippe og lime inn pakkenavnet når man skal legge det til i et prosjekt.
- b) Er det et populært/velkjent prosjekt? Hvor mange stjerner og forks har repoet?

19.2 R

Installering av pakker for R-miljøet i Jupyterlab er foreløpig ikke en del av ssb-project. Men vi kan bruke renv. Mer kommer.

19.2.1 Installering

For å installere dine egne R-pakker må du opprette et virtuelt miljø med **renv**. Gå inn i **Jupyterlab** og åpne R-notebook. Deretter skriver du inn følgende i kodecelle:

```
renv::init()
```

Denne kommandoer aktiverer et virtuelt miljø i mappen du står i. Rent praktisk vil det si at du fikk følgende filer/mapper i mappen din:

renv.lock

En fil som inneholder versjoner av alle pakker du benytter i koden din.

renv

Mappe som inneholder alle pakkene du installerer.

Nå som vi har et virtuelle miljøet på plass kan vi installere en R-pakke. Du kan gjøre dette fra både terminalen og fra en Notebook. Vi anbefaler på gjøre det fra terminalen fordi du da får tilbakemelding på om installeringen gikk bra heller ikke. For å installere i terminalen gjør du følgende:

- 1. Åpne en terminal i Jupyterlab
- 2. Stå i mappen der du aktiverte det virtuelle miljøet
- 3. Skriv in R og trykk enter.

Det vi nå har gjort er å åpne \mathbf{R} fra terminalen slik at vi kan skrive R-kode direkte i terminalen. Det omtales ofte som en R Console. Nå kan du skrive inn en vanlig kommando for å installere R-pakker:

```
install.packages("PxWebApiData")
```

Over installerte vi pakken PxWebApiData som er en pakke skrevet i SSB for å hente ut data fra vår statistikkbank. La oss bruke pakken i koden vår med ved å skrive følgende i kodecelle i Notebooken vår:


Når vi nå har brukt **PxWebApiData** i koden vår så kan vi kjøre en kommando som legger til den pakken i **renv.lock**. Men før vi kan gjøre det må vi være obs på at **renv** ikke klarer å gjenkjenne pakker som er i bruk Notebooks (ipynb-filer). Det er veldig upraktisk, men noe vi må forholde oss til når vi jobber med **renv** i Jupyterlab. En mulig løsning for dette er å bruke Jupytext til å synkronisere en ipynb-fil med en Rmd-fil. **renv** kjenner igjen både R- og Rmd-filer. For å synkronisere filene gjør du følgende:

- 1. Trykk Ctrl+Shift C
- 2. Skriv inn **Pair** i søkefeltet som dukker opp
- 3. Velg Pair Notebook with R Markdown

Hvis du nå endrer en av filene så vil den andre oppdatere seg, og **renv** vil kunne oppdage om du bruker en pakke i koden din. Men for å trigge **renv** til å lete etter pakker som er i bruk så må du skrive følgende kode i Notebooken eller R Console:

renv::snapshot()

Kikker du nå inne i **renv.lock**-filen så ser du nå at verjsonen av **PxWebApiData** er lagt til. I bildet under ser du hvordan et arbeidsmiljø typisk kan se ut når man installerer sine egne pakker.



19.2.2 Avinstallering

19.2.3 Oppgradere pakker

20 Samarbeid

Noen har opprettet et s
sb-project og pushet til Github. Hvordan skal kollegaer gå frem for å bidra inn i koden?

21 Vedlikehold

Part IV Jupyterlab på bakken

22 Installere pakker

22.1 Python

Installering av pakker i Jupyter miljøer på bakken (f.eks https://sl-jupyter-p.ssb.no) foregår stort sett helt lik som på Dapla. Det er én viktig forskjell, og det er at installasjon skjer via en proxy som heter Nexus.

22.1.1 Pip

Pip er ferdig konfigurert for bruk av Nexus og kan kjøres som beskrevet for Dapla

22.1.2 Poetry

Hvis man bruker Poetry for håndtering av pakker i et prosjekt, så må man kjøre følgende kommando i prosjekt-mappe etter prosjektet er opprettet.

```
poetry source add --default nexus `echo $PIP_INDEX_URL`
```

Da får man installere pakker som vanlig f.eks

poetry add matplotlib



🛕 Hvis man forsøker å installere prosjektet i et annet miljø (f.eks Dapla), så må man fjerner nexus kilden ved å kjøre

poetry source remove nexus

22.2 R

Prosessen med å installere pakker for R på bakken er veldig lik slik det gjøres på Dapla. Under beskriver hvordan det avviker fra prosedyren på Dapla.

22.2.1 Installering

Vi installerer fra en proxy-server på bakken, og derfor må vi spesifisere denne adressen manuelt før vi kan installere R-pakker.

```
repos <- c(CRAN = "https://nexus.ssb.no/repository/CRAN/")
options(repos = repos)</pre>
```

Deretter kan du initiere det virtuelle miljøet med følgende kommando:

```
renv::init()
```

Resten er likt som det som er forklart for Dapla.

22.2.2 Avinstallering

22.2.3 Oppgradere pakker

23 Lese inn filer

Mer kommer.

- 23.1 sas7bdat
- 23.2 Oracle
- 23.3 Fame
- 23.4 Tekstfiler
- 23.5 Parquet

Part V Avansert

24 Lese filer fra bøtte

Skal man lese fra en bøtte må man autentisere seg. For å gjøre dette kan man benytte pakken dapla-toolbelt.

24.1 Eksempler



🛕 "navn-boette" eksisterer ikke og må byttes med en reel bøtte.

Les json fil fra bøtte:

```
import dapla as dp
data_frame = dp.read_pandas("gs://ssb-staging-navn-boette/schema.json",
file_format="json")
```

List ut mapper i bøtta:

```
from dapla import FileClient
FileClient.ls("gs://ssb-staging-navn-boette/")
```

24.2 Vanlige problemer

24.2.1 Feil miljø

En vanlig årsak til feil er at man forsøker å lese data fra et annet miljø enn det man befinner seg i. Sjekk at url feltet i nettleseren stemmer overens med bøttene man forsøker å aksessere.

Stagingbøtter starter med: gs://ssb-staging-

Produksjonsbøtter starter med: gs://ssb-prod-

⚠ I https://jupyter.dapla-staging.ssb.no/ kan man ikke lese produksjonsbøtter.

⚠ I https://jupyter.dapla.ssb.no/ kan man ikke lese stagingbøtter.

24.2.2 Omstart av Jupyter

Noen ganger kan en restart av Jupyter løse problemet.

I Jupyters filmeny velg: fil -> Hub Controll Panel.

Trykk på knappen "Stop My Server". Etter dette kan man trykke knappen "Start My Server".




Figure 24.1: Stop My Server

24.2.3 Opprett TMS sak

Hvis man fortsatt ikke har tilgang, kan man opprette en TMS sak. For at vi lettes mulig skal kunne hjelpe bør saken inneholde full feilmelding & relevant kode.

25 IDE'er

Forklare situasjonen nå. Kun Jupyterlab. Kan kjøre remote session med R
studio, Pycharm og VSCode.

- 25.1 RStudio
- 25.2 VSCode
- 25.3 Pycharm

26 Schedulering

27 Databaser

- 27.1 BigQuery
- 27.2 CloudSQL

Referanser